게임 Starfield 리뷰어는 누가, 언제, 얼마나 실망하는가.

플레이 행동과 리뷰 텍스트로 본 평가

3조 김민재 , 최용준

목차

1. 분석 개요
2. 데이터 소개
3. 품질 점검
4. 탐색적 데이터 분석
5. 리뷰 텍스트 기반 추천확률 산출
6. 유저 유형 도출 : K-Means 군집분석
7. 종합분석: 페르소나 x 추천 확률
8. 결론과 한계
9. 참고문헌

분석 개요 - 1. 주제와 사전 조사

주제

· 평가가 갈리는 대작 게임 Starfield에서, 어떤 유형의 유저가 어떻게 평가하는가

왜 Starfield인가

· 후보 게임들의 플레이타임 구간별 긍정률을 같은 API로 수집해 비교 (2026-09-02 기준)

· RDR2는 2시간 이후 전 구간에서 긍정률 89~96%로 사실상 상수
  → 어떤 모델을 붙여도 "다들 좋아한다"는 결론밖에 나오지 않음

· Starfield는 같은 축에서 17.9% → 67.7%로 50%p 가까이 움직임
  → 설명해야 할 분산이 실제로 있는 게임

사전 조사

· 계획 단계에서 후보 4개 게임의 리뷰를 같은 API로 수집해 비교 (우측 표)

게임	리뷰 수	긍정률	판단
Starfield	175,210*	56%	선정. 플레이타임 구간별 긍정률 17.9% → 67.7%
RDR2	913,006	92.5%	제외. 2h 이후 89~96%로 상수, 부정 리뷰 7.5%뿐
Cyberpunk 2077	977,133	86.9%	제외. 출시 4개월 80.3% → 최근 12개월 94.9%로 회복한 사례
Diablo IV	74,979	65.2%	제외. 라이브서비스 ARPG라 시즌마다 복귀·이탈 반복

* 계획 단계 수집(2026-09-02) 기준. 최종 수집(09-08)은 175,300건 (6p) — 6일 사이 추가된 리뷰

분석 개요 - 2. 선행연구

선행연구	무엇을 밝혔나	이 프로젝트에서의 쓰임
[1] Steam 리뷰 감성 → 이탈 예측 (SNAM, 2024)	SVM 감성 점수를 시계열에 넣어 이탈을 예측 (정확도 89%)	"리뷰 감성 → 유저 행동" 프레임의 근거. 단, 시계열 단위 → 우리는 개인 단위
[2] Steam 리뷰 길이와 감성 (Computers in Human Behavior, 2023)	리뷰 길이와 감성의 관계를 장르 단위로 분석	길이가 교란변수라는 근거 → 5장에서 "길이만" 기준선을 세움
[3] Steam 리뷰 토픽 모델링 비교 (IEEE Trans. on Games, 2024)	Steam 리뷰(No Man's Sky)에서 임베딩 기반 방법이 LDA·NMF보다 우수	같은 데이터 종류에서 임베딩 접근이 통한다는 도메인 근거
[4] MTEB 벤치마크 (EACL, 2023)	텍스트 임베딩 모델을 분류·군집 등 과제로 표준 평가	5장 임베딩 모델 선정 기준 (다국어 리더보드)
[5] 임베딩의 길이 취약성 (EMNLP, 2023)	문장 임베딩에 길이 성분이 실재해 의미 비교를 왜곡	언어별·길이별 성능을 따로 점검한 이유 (5장)

본 프로젝트의 위치

· 선행연구는 시계열·장르·게임 단위, 대부분 영어 단일 언어 → 우리는 리뷰어 개인 단위, 29개 언어 전량을 다국어 임베딩으로 통합

· 유저 유형(플레이 행동)과 리뷰 텍스트 점수를 결합해 "어떤 유형이 어떻게 평가하는가"를 묻는 접근은 확인한 범위에서 찾지 못함 (출처는 9장 참고문헌)

분석 개요 - 3. 핵심 질문과 분석 흐름

핵심 질문

Q1. 리뷰 텍스트만으로 추천/비추천을 얼마나 정확히 예측할 수 있는가? → 5장

Q2. 플레이 행동(보유 게임 수·리뷰 수·플레이시간·업적)으로 Starfield 리뷰어를 어떤 유형으로 나눌 수 있는가? → 6장

Q3. 유저 유형에 따라 평가(추천 여부·추천확률)가 어떻게 다른가? → 7장

가설

· H1. 게임 경험이 많은 유형(보유 게임·작성 리뷰 多)일수록 비판적일 것이다

· H2. 플레이시간이 짧은 시점에 쓴 리뷰일수록 부정적일 것이다

분석 대상

· Steam 리뷰 API + 업적 API로 수집한 Starfield 리뷰어 72,271명 → 정제 후 70,915명

단계	입력	방법	산출
① 평가 점수	리뷰 텍스트	다국어 임베딩 + 로지스틱 회귀	추천확률 0~1 (5장)
② 유저 유형	플레이 변수 4개	K-Means 군집	페르소나 3개 (6장)
③ 결합	① × ②	유형별 비교 (groupby)	누가·언제·얼마나 실망했나 (7장)

두 결과가 만나는 지점(③)이 이 분석의 결론. ①과 ②는 서로 독립적으로 만들어 7장에서 처음 결합한다.

데이터셋 소개 - 72,271 행 x 36 열

· 수집 2단계: ① 리뷰 API(appreviews) → 리뷰 전체 175,300건(09-08 기준) ② 각 steamid의 업적 API → 프로필·업적 공개 유저 72,271명(41%)만 조회 가능 → 분석 대상
· 비공개 유저가 빠지는 표본 편향 가능성은 한계에 기록. 36열 중 ○ 표시한 10개 변수 + 업적 파생 3개를 분석에 사용

1. 리뷰 관련 컬럼

열 이름	타입	내용	값 범위 · 주의	사용
voted_up	bool	추천 / 비추천	긍정률 약 57%	○
recommendationid	int	리뷰 고유 ID	전부 고유. steamid 와 1: 1	–
language	str	리뷰어의 Steam 클라이언트 언어 설정*	29종	○
review	str	리뷰 본문	192건 NaN. 최장 8,000자	○
ts_created	int	리뷰 최초 작성 시각	2023-09-06 ~ 2026-09-07 (출시 당일부터, 출시 전 리뷰 0건)	○
ts_updated	int	리뷰 마지막 수정 시각	미수정시 위 컬럼과 동일	–
app_release_date	int	게임 출시일	전부 2023-09-06 (상수)	–
written_during_early_access	bool	얼리엑서스 중 작성	전부 False	–

데이터셋 소개

2. 리뷰에 대한 타인의 반응 — 분석 미사용 (참고)

열 이름	타입	내용	값 범위 · 주의	사용
votes_up	int	“유용함” 투표 수	최대 15,871 / 46.6%가 0.	–
votes_funny	int	“재미있음” 투표 수	최대 3,456 / 82.5%가 0	–
weighted_vote_score	float	Steam 자체의 유용성 점수	0.04~0.971. 49.5%가 0.5 = 기본값	–
comment_count	int	댓글 수	최대 625, 96.5%가 0	–
reactions	str(list)	이모지 반응	89.2%가 빈 리스트. 문자열로 저장됨	–
timestamp_dev_responded	float	개발사 답변 시각	1,355건(1.9%)만. 전부 2023-09-11	–
developer_response	str	개발사 답변 본문	위와 동일 건. 정형 문구	–

데이터셋 소개

3. 구매·플랫폼 플래그 — 분석 미사용 (참고)

열 이름	타입	내용	값 범위 · 주의	사용
steam_purchase	bool	Steam에서 직접 구매	True 57.0%	–
received_for_free	bool	무료로 받음	True 2.7%	–
refunded	bool	환불 여부	True 41건	–
primarily_steam_deck	bool	주로 Steam Deck으로 플레이	True 0.7%	–
deck_playtime_at_review	float	리뷰 시점 Deck 플레이 시간	96.2% 결측	–

데이터셋 소개

4. 작성자 프로필

열 이름	타입	내용	값 범위 · 주의	사용
steamid	int	전부 고유 = 1인 1리뷰	모든 파일의 병합 키	○
personaname	str	닉네임		–
profile_url	str	프로필 URL		–
avatar	str	아바타 해시		–
persona_status	str	수집 시점 접속 상태	offline 78%	–
games_owned	int	보유 게임 수	중앙값 235, 최대 36,496.	○
num_reviews	int	작성한 리뷰 총 수	최소 1, 중앙값 14, 최대 25,829	○

데이터셋 소개

5. 플레이타임 (단위: 분)

열 이름	타입	내용	값 범위 · 주의	사용
playtime_at_review_min	int	리뷰 시점까지 누적 플레이타임	최소 5, 중앙값 2,258분(38h), 최대 503,105	○
playtime_forever_min	int	수집 시점 까지 누적 플레이타임	중앙값 4,628분(77h), 최대 1,016,252분	○
playtime_2w_min	int	수집 시점 기준 최근 2주 플레이	96.3%가 0 - 2023년 리뷰어에겐 무의미	–
last_played	int	마지막 플레이 시각	2023-09 ~ 2026-09	○

- 이 외에도 하드웨어 관련 변수들이 있으나 (예: system_ram, os, cpu_name…) 2025년경 Steam이 추가한 항목으로 해당 분석에서는 사용할수 없다고 판단했다.(결측 98.5%)
- 결측비율이 과하게 높거나 해당 분석에서의 의미가 없다고 판단되는 변수들 제외 10개의 변수를 선정해서 사용했다.
- 선정 변수: steamid, language, review, ts_created, voted_up, games_owned, num_reviews, playtime_at_review_min, playtime_forever_min, last_played

데이터셋 소개

6. 업적 데이터

- 해당 데이터는 유저가 획득한 업적들의 이름과 각 업적별 획득 시각이 적혀있다. 이대로 사용하기에는 어렵기 때문에 파생변수로 만들었다.

열 이름	타입	내용	값 범위 · 주의	사용
stage_at_review	int	리뷰 시점의 메인 퀘스트 단계	stage(0~10)*. 2단계에 42.8% 집중	○
n_ach_at_review	int	리뷰 시점 전체 업적 수	중앙값 10. 0인 2,526건 중 999건은 미추적, 1,527건은 리뷰 전엔 업적이 없던 초반 리뷰어	○
n_ach_total	int	수집 시점 전체 업적 수	중앙값 23, 최대 82 (= 총 업적 수**). 0인 999건 = 조기 이탈 또는 업적 비활성화(12p)	○
stage_final	int	수집 시점 최종 퀘스트 단계	stage(0~10). 10단계에 40.4%, 2단계에 27%	–

* stage: 메인 퀘스트 업적 10개를 진행 순서로 번호 매김(1 For All, Into the Starfield … 8 Entangled → 9 Unearthed → 10 One Giant Leap), 리뷰 시점까지 해금한 것 중 가장 뒤 단계. 8·9 순서는 실측(둘 다 해금한 31,119명 중 26,982명이 Entangled 먼저)으로 확정
** n_ach 최댓값 82 = Starfield 총 업적 수(본편+DLC)와 일치. 403명이 정확히 82개 → 수집 오류 아님

데이터 품질 점검

1. 분석 대상 제외

- 4개 기준 중 하나라도 해당하면 제외
- 1,356건(1.9%) 제외 → 최종 70,915건

제외 기준	건수	이유
업적 미추적 (n_ach_total = 0)	999	업적 비활성화 + 조기 이탈 혼재*
라이브러리 비공개 (games_owned = 0)	167	보유자라 0은 불가
리뷰 텍스트 없음	192	임베딩 대상 없음
플레이타임 오류	2	리뷰 시점 > 총
합계 (중복 제외)	1,356	→ 70,915건 (98.1%)

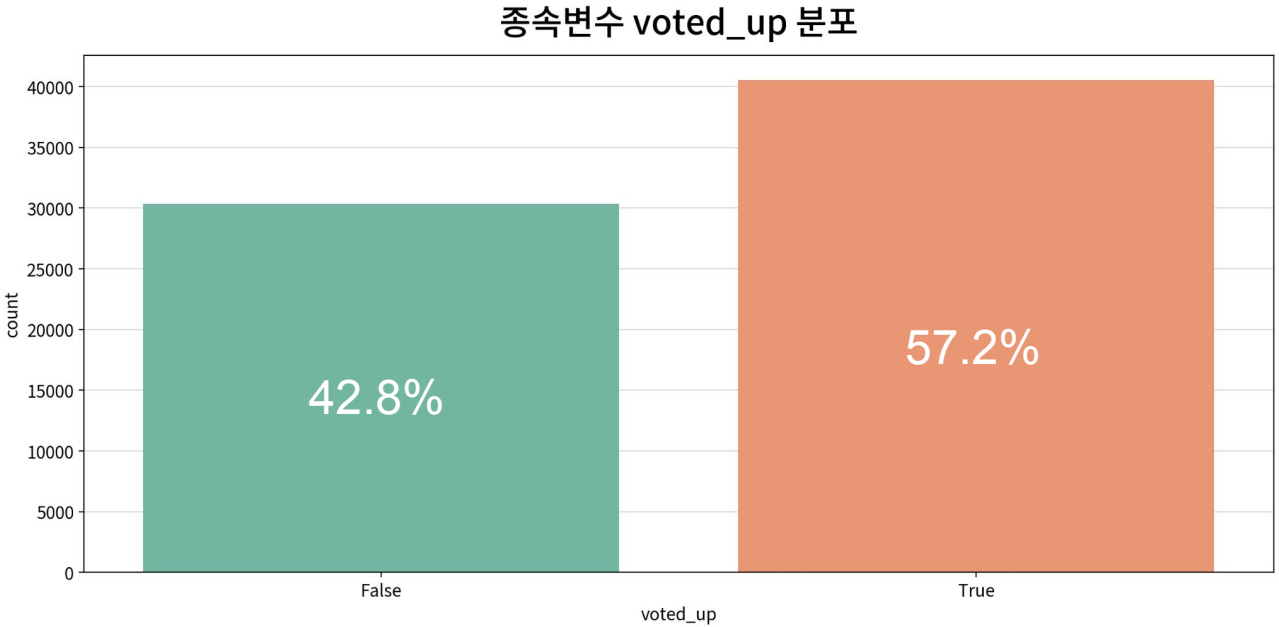
2. 이상치

① 논리적 이상치 제거: 리뷰 시점 > 총 플레이 (2건)
② 상한값 대체(윈저라이징): 상위 0.5% 지점 값보다 큰 355건을 그 값으로 바꿈 (제거 아님)
n_ach_at_review는 상한 82 = 완주라 대체 안 함

열 이름	최솟값	최댓값	대체값 (상한)
games_owned	1.00	36,496.00	3,466.72
num_reviews	1.00	25,829.00	281.43
playtime_at_review_min	5.00	503,105.00	38,822.02

* 업적 0개 999명은 두 집단: 총 플레이 5시간 미만 458명(첫 업적 전에 그만둔 조기 이탈 추정, 긍정률 24%) + 5시간 이상 541명(정상 플레이에서 5시간 후 업적 0개는 1% 미만 → 모드·콘솔로 업적이 꺼진 상태로 추정, 그중 100시간 이상 153명). 후자는 진행 단계를 알 수 없고 전자는 수가 적어 함께 제외. 가장 부정적인 초기 이탈자가 빠지는 영향은 한계(34p)에 기록.

탐색적 데이터 분석 - 1. 명목형 종속변수 단변량 분석



대체로 균등한 분포

추천 40,542 건 (57.2%)
비추천 30,373 건 (42.8%)

탐색적 데이터 분석 - 2. 군집분석에 사용할 변수의 기술통계량 (상한값 대체 후, 70,915건)

	games_owned	num_reviews	playtime_at_review_min	n_ach_at_review
min	1.00	1.00	5.00	0.00
max	3,466.72	281.43	38,822.02 (647h)	82.00
mean	376.67	26.94	3,804.02 (63h)	14.67
50%	237.00	14.00	2,286.00 (38h)	10.00
std	456.78	38.22	5,087.64	12.89
skew	3.54	3.55	3.59	1.07
kurt	16.53	16.26	17.21	0.54
해석	분산이 큼 평균>중앙값 차이 큼 왜도, 첨도 높음	분산이 큼 평균>중앙값 차이 큼 왜도, 첨도 높음	분산이 큼 평균>중앙값 차이 큼 왜도, 첨도 높음	왜도·첨도 낮음 (약간 치우침). 최솟값 0
판단	오른꼬리 형태 로그변환 필요	오른꼬리 형태 로그변환 필요	오른꼬리 형태 로그변환 필요	척도 통일을 위해 로그변환(log1p) 선택

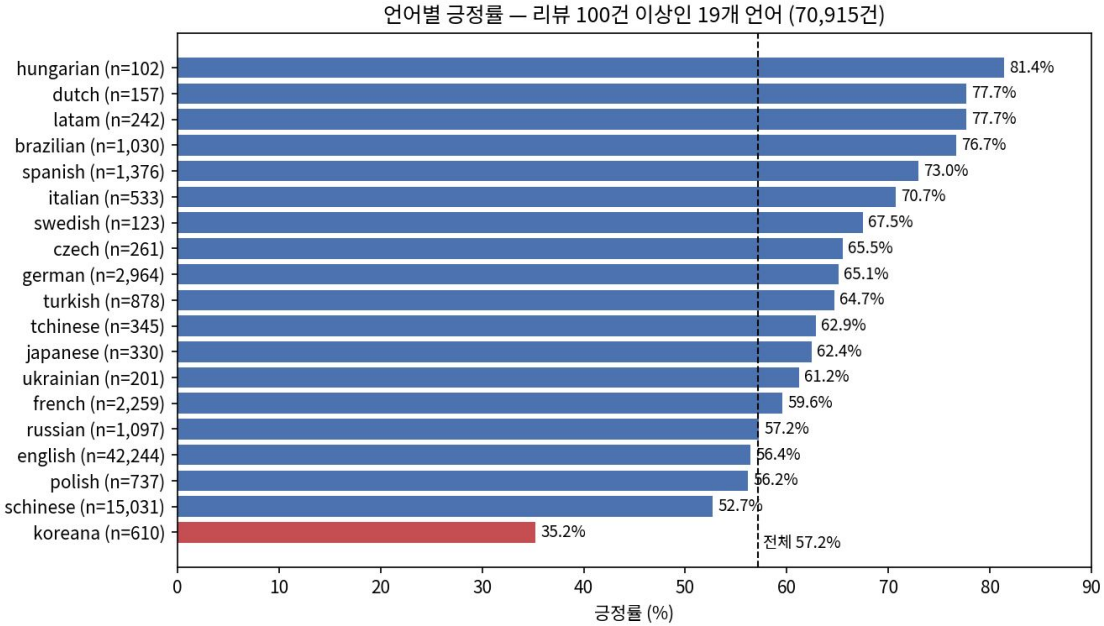
탐색적 데이터 분석 - 3. 군집 변수 선정을 위한 상관 확인

- 상관 0.8 이상 쌍은 하나만: stage_at_review(0.847) 대신 n_ach_at_review(값 범위 0~82로 정보량 많음)
- 리뷰 이후 변하는 "최종" 변수(stage_final 등)는 제외 → 군집 변수 4개 확정. VIF는 참고용(모두 10 미만)

	games_owned	num_reviews	playtime_forever_min	playtime_at_review_min	stage_final	n_ach_total	stage_at_review	n_ach_at_review
games_owned	1.000	0.501	-0.017	0.044	0.007	0.031	0.027	0.055
num_reviews	0.501	1.000	-0.055	-0.049	0.006	0.008	-0.048	-0.051
playtime_forever_min	-0.017	-0.055	1.000	0.720	0.571	0.744	0.348	0.489
playtime_at_review_min	0.044	-0.049	0.720	1.000	0.462	0.574	0.599	0.765
stage_final	0.007	0.006	0.571	0.462	1.000	0.855	0.649	0.610
n_ach_total	0.031	0.008	0.744	0.574	0.855	1.000	0.551	0.679
stage_at_review	0.027	-0.048	0.348	0.599	0.649	0.551	1.000	0.847
n_ach_at_review	0.055	-0.051	0.489	0.765	0.610	0.679	0.847	1.000

	n_ach_at_review	n_ach_total	stage_at_review	stage_final	playtime_at_review_min	playtime_forever_min	num_reviews	games_owned
VIF	6.484	5.531	5.226	4.549	2.740	2.533	1.221	1.213

탐색적 데이터 분석 - 4. 언어별 긍정비율 확인



- 리뷰 100건 이상인 19개 언어 중 한국어가 긍정률 35.2%(n=610)로 최저. 영어 56.4%(42,244) · 중국어 52.7%(15,031) · 독일어 65.1%(2,964) · 스페인어 73.0%(1,376)
- 언어에 따라 긍정률이 35~81%까지 다르다 → 한 언어만 쓰면 표본이 편향된다. 5장에서 다국어 모델을 쓰는 근거
- language는 Steam 클라이언트 설정값(실제 글의 언어와 다를 수 있음)

리뷰 텍스트 기반 추천확률 산출

리뷰의 감성은 추천/비추천 버튼 하나로는 다 담기지 않는다. 추천을 누르고도 불만을 길게 쓴 리뷰가 있기 때문이다.

유저 유형(6장)별로 평가를 비교하려면 리뷰마다 연속적인 평가 점수가 필요하다. 그래서 먼저 리뷰 텍스트에서 "추천확률"이라는 연속 점수를 뽑고, 이 점수가 믿을 만한지 확인한다.

이 모델은 감성을 재는 것이 아니라 리뷰 텍스트로 추천 여부(voted_up)를 맞히는 분류기다. 그 예측확률을 뒤의 모든 분석에서 평가를 재는 잣대로 쓴다.

리뷰 텍스트 기반 추천확률 산출 - 1. 접근 방법

왜 다국어 임베딩인가

· 리뷰 70,915건이 29개 언어 (영어 59.6% · 중국어 21.2% · 기타 19.2%)

· 영어만 쓰면 40%를 버리고, 버려지는 쪽의 긍정률이 다름

(중국어 53% · 독일어 65% · 한국어 35%) → 표본 편향

· 언어별 형태소 분석 대신 다국어 임베딩 모델 하나로 통일, 원문 그대로 입력

모델

· multilingual-e5-large (1,024차원) — MTEB 다국어 리더보드 기준 선정, 상위 모델 Qwen3-Embedding-0.6B와 실측 비교 후 확정

· e5 권장대로 입력 앞에 "query: " 접두어를 붙여 임베딩

· 임베딩 → 로지스틱 회귀로 추천/비추천 예측 → 예측확률을 "추천확률"로 사용

· 로지스틱 회귀 설정: L2 규제 C=1(기본), class_weight 없음(확률 보정 유지),

lbfgs, max_iter=300, 시드 3217 고정

단계	내용
① 입력	리뷰 원문 (전처리 없음)
② 임베딩	multilingual-e5-large (Colab GPU, 1,024차원)
③ 분류	로지스틱 회귀 (L2, C=1) → 추천 여부
④ 산출	추천확률 (0~1)

리뷰 텍스트 기반 추천확률 산출 - 2. 분류 성능 (voted_up 예측)

모델	평가 방식	AUC	정확도
리뷰 길이만 (기준선)	holdout 20%	0.5740	0.5803
multilingual-e5-large	holdout 20%	0.9537	0.8867
Qwen3-Embedding-0.6B (비교)	holdout 20%	0.9530	0.8838
e5, 중복 텍스트 격리 분할*	holdout 20% (그룹)	0.9497	0.8831
e5, 5-fold out-of-fold	전체 70,915건	0.9541	0.8869

· 길이 기준선 대비 AUC +0.38 → 길이가 아니라 내용을 읽음

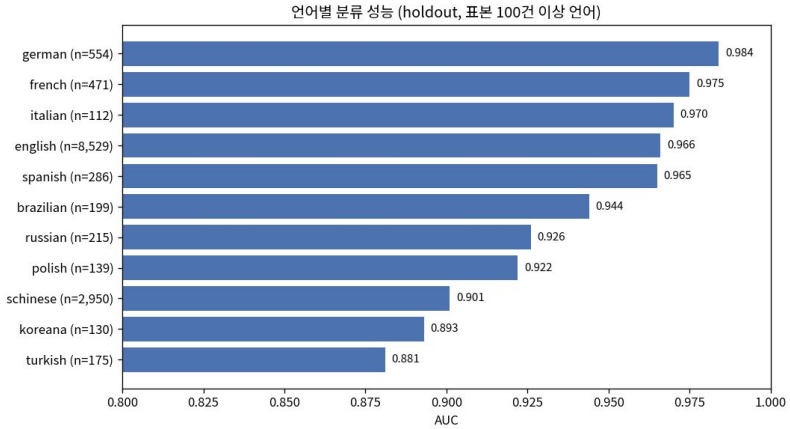
· 리더보드 상위 Qwen3보다 우리 데이터에서는 e5가 근소 우위

· OOF 비추천 재현율 0.858 · 정밀도 0.876 (추천 0.909 · 0.895)

→ 비추천 7건 중 1건은 추천으로 잘못 읽음

· 언어별 AUC 0.88~0.98 (표본 100건 이상 11개 언어). 50자 이상만 봐도 격차 유지

→ 길이가 아닌 모델의 언어별 표현력 차이 (한계). holdout과 OOF가 넷째 자리에서만 다름



* 중복 텍스트 격리: "good", "10/10" 같은 똑같은 리뷰가 학습·평가 양쪽에 들어가면 점수가 부풀려지므로, 같은 텍스트(4,706건)는 한쪽에만 두도록 나눔

· 유저 유형별(6장) AUC 0.948~0.963 → 세 유형 모두 0.9 이상, 모델이 유형에 공평 (7장의 전제)

리뷰 텍스트 기반 추천확률 산출 - 3. 추천확률 산출과 보정

추천확률 = P(추천 | 리뷰 텍스트)

· 1에 가까울수록 텍스트가 추천에 가깝다

· 전체 리뷰에 5-fold out-of-fold로 부여 (중복 텍스트는 같은 fold에 격리)

— 모든 리뷰가 자기를 학습하지 않은 모델로 채점됨

(holdout 모델을 전체에 적용하면 학습 행 80%가 과신 방향으로 치우침)

보정 확인

· 예측확률 구간별 실제 추천 비율이 예측값과 거의 일치

· → 확률값을 그대로 연속 점수로 사용 가능

7장에서 쓰는 구간 (경계 통일)

· 부정 0.3 미만 24,434건 / 중간 0.3 이상 0.7 미만 11,106건 (15.7%) / 긍정 0.7 이상 35,375건

추천확률 구간	리뷰 수	실제 추천 비율	평균 예측
0.0 ~ 0.1	15,577	2.8%	0.036
0.1 ~ 0.3	8,857	15.1%	0.184
0.3 ~ 0.5	5,311	36.2%	0.397
0.5 ~ 0.7	5,795	60.0%	0.609
0.7 ~ 0.9	10,167	85.1%	0.817
0.9 ~ 1.0	25,208	98.1%	0.968

유저 유형 도출 : K-Means 군집분석 - 1. 개요

- 유저들을 특성에 따라 집단으로 나누어 비교, 분석하기 위하여 군집화를 시도

- K-Means 선정 이유 : 1. 연속형 변수 처리에 적합 : 투입 변수가 모두 연속형

  2. 계산 속도가 빠름 : 약 7만 건의 표본 처리에 적합

- 유저 특성을 나타낼 수 있는 변수들을 선정 : 1. 유저의 게임 경험 (보유 게임 수, 작성 리뷰 수)

  2. 해당 게임 몰입도 (리뷰시점 플레이 시간, 리뷰 시점 총 업적 수)

  - 상관이 높은 변수의 중복 배제, 시간의 선후를 고려해 리뷰 이후 변수 제외

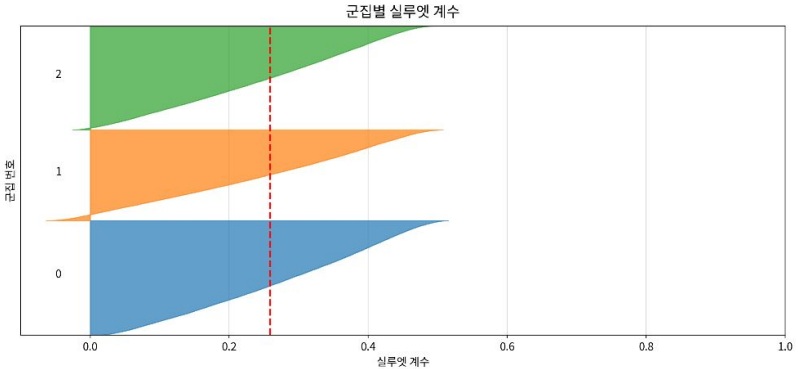
- 기술통계량 분석 결과(p.)에 따라 각 변수에 로그변환 적용

- 변수간 규모차이를 줄이기 위해 스케일링(StandardScaler) 적용

- 군집화 결과는 페르소나로 정리해 다음 단원에서 추천확률 산출 결과와 연결하여 분석

K-Means 군집분석 - 2. 최적의 군집 수(k) 찾기

k	스코어	전체면적	두께비	최소상대면적	균형지수
2	0.279	19789.913	1.463	0.684	0.131
3	0.259	18349.433	1.264	0.826	0.169
4	0.231	16345.422	1.753	0.725	0.095
5	0.214	15188.546	2.007	0.642	0.069
6	0.215	15225.978	1.913	0.684	0.077
7	0.203	14396.838	2.126	0.645	0.062
8	0.203	14357.201	1.724	0.681	0.080
9	0.193	13675.849	2.156	0.650	0.058
10	0.191	13518.799	2.150	0.671	0.059



- 균형지수 = 스코어 x 최소상대면적 / 두께비
  - 실루엣 스코어(클수록 좋음)
  - 두께비(1에 가까울수록 좋음)
  - 최소상대면적(1에 가까울수록 좋음)

- 군집 수 k=2 : 플레이시간이 많은 그룹과 적은 그룹으로만 분리되어 유저의 게임 경험 관련 변수의 변별력이 없어짐

- 최적 군집 수 k = 3

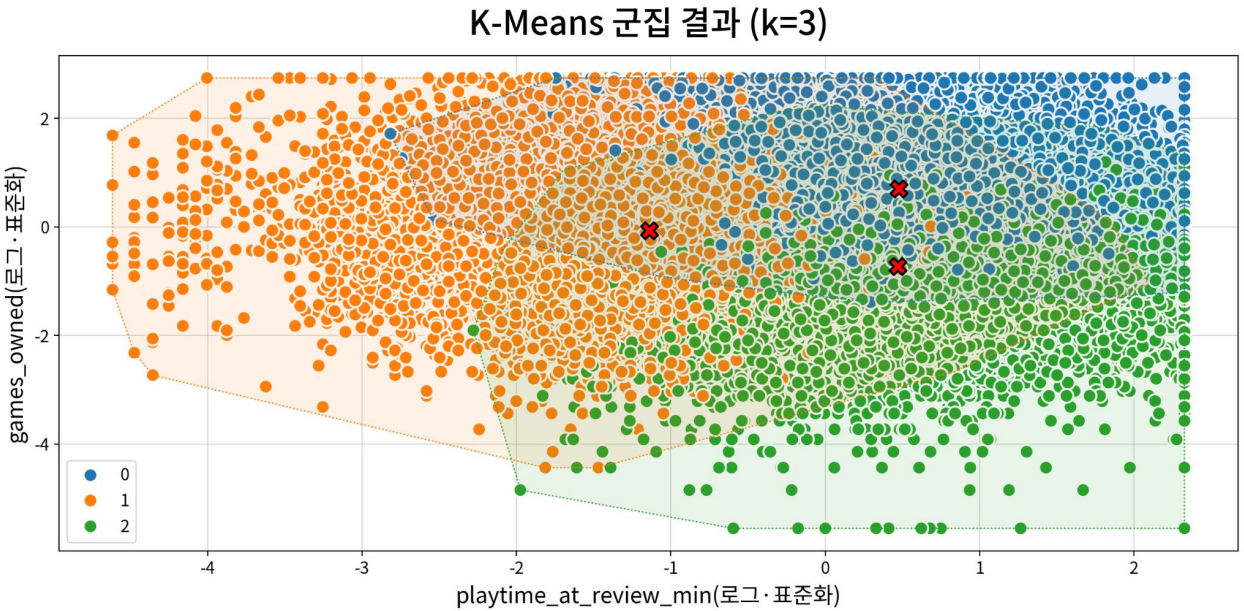
- 주의점 : 실루엣 스코어 = 0.259로 비교적 낮음
  -> 경계가 명확하지 않아 군집 간 겹치는 부분이 존재

K-Means 군집분석 - 3. 페르소나 분석

- K-Means 군집 후 집단의 특성을 분석하여 페르소나 도출
- 정규성 검정 결과, 모두 정규분포를 따르지 않아 중앙값을 사용하여 비교
- 리뷰 이후 플레이시간 = 총 플레이시간 - 리뷰 시점 플레이시간
- 리뷰 이후 이탈 비율 : 리뷰 이후 플레이시간이 1시간 미만인 유저 비율

군집	이름	인원(%)	보유 게임 수	작성 리뷰 수	리뷰 시점 플레이시간 (h)	리뷰 시점 업적 수	리뷰 이후 플레이시간 (h)	리뷰 이후 이탈 비율	긍정률
0	하드 리뷰어	26,300 (37.1%)	431	29	55.62	17	20.30	0.407	0.574
1	초기 리뷰어	20,805 (29.3%)	220	16	8.18	3	9.68	0.503	0.478
2	라이트 리뷰어	23,810 (33.6%)	124	5	53.93	16	28.86	0.341	0.650
전체		70,915 (100%)	237	14	38.1	10	19.72	0.413	0.572

K-Means 군집분석 - 4. 군집화 결과(페르소나)

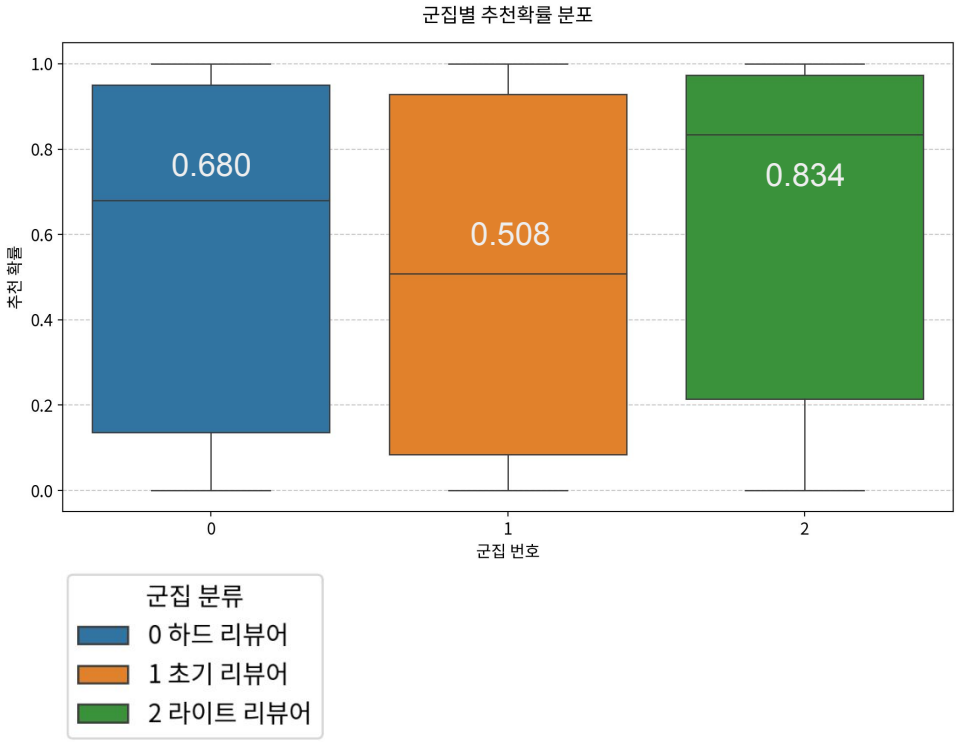


군집 0 (하드 리뷰어)
보유 게임 수와 작성 리뷰 수,
플레이시간이 모두 많음

군집 1 (초기 리뷰어)
리뷰 시점 플레이시간과 업적 수가
상대적으로 적음

군집 2 (라이트 리뷰어)
보유 게임 수와 작성 리뷰수는
적지만
플레이시간이 많음

종합분석 : 페르소나 x 추천확률 - 1. 누가 만족/불만족했나

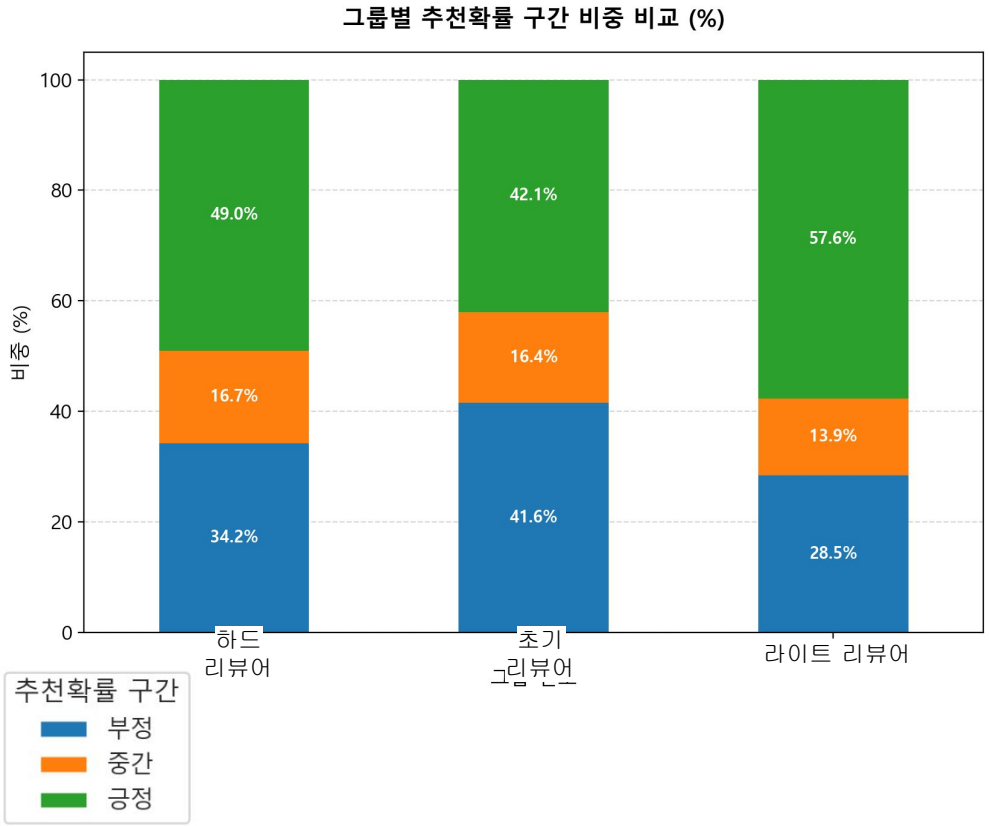


- 라이트 리뷰어 > 하드 리뷰어 > 초기 리뷰어 순으로 추천확률 중앙값이 높게 나타났다.
라이트 리뷰어는 하드 리뷰어보다 중앙값이 **0.154** 높다.
초기 리뷰어는 하드 리뷰어보다 중앙값이 **0.172** 낮다

- 평균적으로 라이트 리뷰어 집단이 가장 만족했고, 초기 리뷰어 집단이 가장 불만족했다.

- 추천확률은 추천 여부를 맞히도록 학습한 점수라 유형별 평균은 긍정률과 거의 같은 정보
→ 추가로 추천 강도·중간 구간·불일치를 확인

종합분석 : 페르소나 x 추천확률 - 2. 얼마나 명확하게 평가했나



- 긍정/부정 강도를 보기 위해 추천확률을 세 구간으로 구분

  부정 : 0.3 미만

  중간 : 0.3 이상 0.7 미만

  긍정 : 0.7 이상

- 긍정 또는 부정 : 명확하게 긍정/부정을 표현한 리뷰

  중간 : 긍정/부정이 혼합되어 있거나 애매한 평가를 내린 리뷰

- 라이트 리뷰어 집단이 명확한 긍정 리뷰 비율(57.6%)이 가장 높았고, 모호한 평가 비율이 가장 적게 나타났다(13.9%).

- 초기 리뷰어 집단이 부정 평가 비율이 가장 높았다(41.6%).

종합분석 : 페르소나 x 추천확률 - 3. 불일치 케이스 분석

[CASE1 불일치 추천 : 추천확률 비추천 구간 & 실제 추천]

快点修复闪退！
(충돌 문제를 최대한 빨리 해결해주세요!)

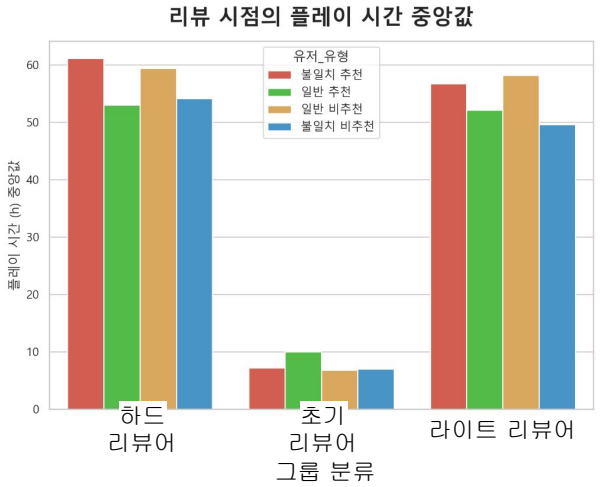
Okay Todd, I bought another Skyrim, but this is definitely the last time, I promise you.
(좋아 토드, 내가 또 다른 스카이림을 사줬지만 이번이 정말 마지막이야, 진짜로.)

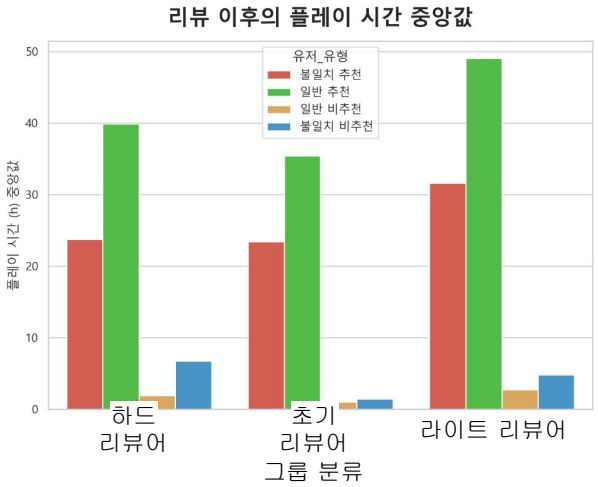
[CASE2 불일치 비추천 : 추천확률 추천 구간 & 실제 비추천]

Okay what people say is true, game great after a bit.(중략) Changing to a negative review until bug causing serious issues on linux is fixed.
(그래 사람들이 말한대로, 조금 하다보니까 게임 완전 재밌어.(중략)리눅스에서 심각한 문제를 일으키는 버그가 수정될 때까지 부정적인 리뷰로 전환할거야.)

- 추천확률의 예측 결과와 실제 추천 여부가 불일치 한 케이스를 분석
- CASE1(불일치 추천) : 추천확률은 비추천 구간이지만 실제로는 추천을 누른 유저 그룹
- CASE2(불일치 비추천) : 추천확률은 추천 구간이지만 실제로는 비추천을 누른 유저 그룹
- 두 불일치 그룹의 리뷰 텍스트 샘플을 뽑아 확인
- CASE1는 주로 불만사항을 토로하고 있지만 개선을 요구
- CASE2는 게임의 장점을 칭찬하지만 몇가지 단점때문에 결론은 비추천

종합분석 : 페르소나 x 추천확률 - 3. 불일치 케이스 분석





- 불일치 추천 그룹은 일반 추천 그룹 (불일치 추천을 제외한 추천 유저)에 비해 리뷰 시점 플레이 시간은 더 많고 (초기 리뷰어 그룹은 예외) 리뷰 이후 플레이 시간은 더 적음

→ 더 많이 플레이 해보고 리뷰 작성 했지만 리뷰 이후에는 더 빨리 이탈 (불만사항이 리뷰 이후 플레이시간 감소와 함께 나타남)

- 불일치 비추천 그룹은 일반 비추천 그룹 (불일치 비추천을 제외한 비추천 유저)에 비해 리뷰 이후 플레이 시간이 더 많음

→ 게임 플레이에 대한 욕구가 아직 남아있음

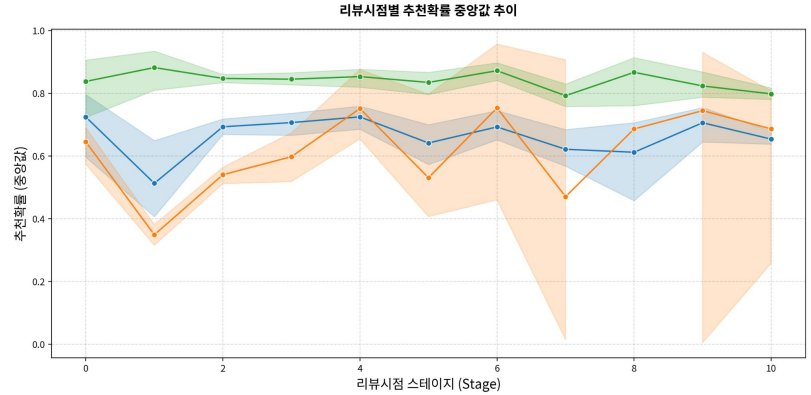
- 두 불일치 그룹은 불만사항 개선을 통해 플레이 시간 증가를 기대해 볼 수 있음

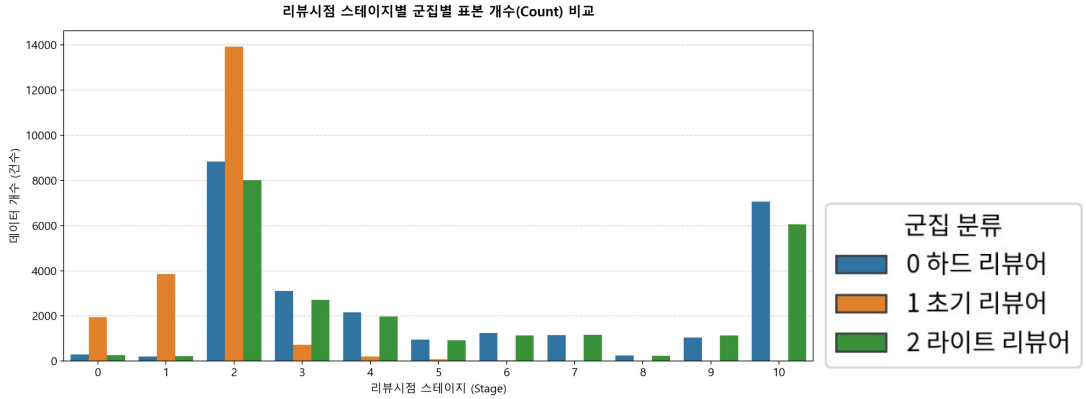
종합분석 : 페르소나 x 추천확률 - 3. 불일치 케이스 분석

그룹이름	부정·추천 수	부정·추천 비율(%)	긍정·비추천 수	긍정·비추천 비율(%)
하드 리뷰어	734	**2.79**	775	2.95
초기 리뷰어	514	2.47	719	**3.46**
라이트 리뷰어	527	2.21	514	2.16

- 하드 리뷰어 집단에서 부정·추천 그룹의 비율이
  가장 높았고(라이트 리뷰어 대비 +0.58%),
  초기 리뷰어 집단에서 긍정·비추천 그룹의 비율이
  가장 높았다(라이트 리뷰어 대비 +1.3%).

종합분석 : 페르소나 x 추천확률 - 4. 어느 지점에서 실망했나





- 초기 리뷰어의 경우 4 스테이지 이후에 작성한 리뷰 수가 적어 추천확률의 변동성이 큼.
- 하드리뷰어와 초기 리뷰어는 초반 1스테이지가 낮은 추천확률을 기록한 것으로 보아 게임 초반부 불만사항이 발생한 것으로 추정.
- 라이트 리뷰어의 경우 다른 그룹과는 달리 1스테이지의 추천확률이 약간 상승함.
- 모든 집단 유형이 스테이지7에서 추천확률이 하락하는 모습이 관찰되는 것으로 보아 공통적인 불만사항이 존재하였을 것으로 보임.

종합분석 : 페르소나 x 추천확률 - 5. 리뷰 이후엔 어떻게 됐나

그룹이름	유저 수 (명)	평균 리뷰 이후 플레이 시간 (h)	중앙값 리뷰 이후 플레이 시간 (h)	유저 잔존 성향 분석
하드 리뷰어	26,300	60.0	20.3	전체 통계와 유사한 플레이 패턴을 보임
초기 리뷰어	20,805	46.7	9.7	중앙값이 10시간 미만으로, 초반 이탈층이 두터움
라이트 리뷰어	23,810	84.6	28.9	평균과 중앙값 모두 높은 잔존 성향을 보여줌
전체	**70,915**	**64.3**	**19.7**	

추천확률 예측 구간	유저 수 (명)	평균 리뷰 이후 플레이 시간 (h)	중앙값 리뷰 이후 플레이 시간 (h)	유저 잔존 성향 분석
부정 (0.3 미만)	24,435	29.3	1.7	초고속 이탈 : 그룹 절반이 리뷰 후 1.7시간 내에 이탈함
중간 (0.3이상 0.7 미만)	11,104	52.4	14.3	완만한 잔존 : 전체 통계보다 조금 적은 시간을 플레이 후 이탈

종합분석 : 페르소나 x 추천확률 - 6. 어디서 다른가

그룹이름	전체 유저 추천확률 중간값 (한국어 제외)	한국어 유저 추천확률 중간값	추천확률 격차 (%p)
하드 리뷰어	0.683	0.527	**-15.674%p**
초기 리뷰어	0.513	0.358	**-15.434%p**
라이트 리뷰어	0.837	0.443	**-39.371%p**

- 한국어 리뷰어는 모든 그룹 유형에서 한국어 외의 언어를 쓰는 유저들에 비해 추천 확률이 낮게 나타났다.

결론과 한계 - 1. 세 질문에 대한 답

Q1. 리뷰 텍스트만으로 평가를 예측할 수 있는가 → 있다

· 다국어 임베딩 + 로지스틱 회귀, 5-fold out-of-fold AUC 0.954 · 정확도 0.887

· 예측확률이 구간별 실제 추천 비율과 일치 → 연속 점수 "추천확률"로 사용

· 세 유저 유형 모두 AUC 0.948~0.963 → 유형 비교에 같은 잣대를 쓸 수 있음

Q2. 플레이 행동으로 리뷰어를 나눌 수 있는가 → 세 유형

· 초기 리뷰어 29%: 플레이 8h · 업적 3개 시점에 리뷰

· 하드 리뷰어 37%: 보유 게임 431 · 리뷰 29편 · 55h

· 라이트 리뷰어 34%: 보유 게임 124 · 리뷰 5편 · 54h

· 실루엣은 k=2(0.279)가 더 높지만 k=2는 플레이시간 축으로만 갈려 게임 경험 축이 사라짐 → 두 축이 모두 드러나는 k=3

Q3. 유형에 따라 평가가 어떻게 다른가 → 우측 표

· 누가·얼마나·언제·그 뒤·어디서가 모두 다르다

질문	결과
누가	추천확률 중앙값 라이트 0.83 > 하드 0.68 > 초기 0.51 (초기는 하드보다 0.17 낮음). 초기 리뷰어는 리뷰의 42%가 명확한 부정(0.3 미만), 라이트는 58%가 명확한 긍정
얼마나	불일치 추천(텍스트 부정·실제 추천)은 하드 리뷰어에 가장 많고(2.8%, 라이트 대비 +0.6%p), 불일치 비추천(텍스트 긍정·실제 비추천)은 초기 리뷰어에 가장 많다(3.5%, +1.3%p). 불일치 추천은 일반 추천보다 리뷰 후 플레이가 짧고, 불일치 비추천은 일반 비추천보다 길다
언제	하드·초기 리뷰어는 1스테이지 리뷰가 가장 부정적. 세 유형 모두 7스테이지에서 함께 하락
그 뒤	추천확률 0.3 미만 리뷰어의 절반은 리뷰 후 1.7시간 안에 그만둠, 0.7 이상은 41시간 더 플레이. 초기 리뷰어 리뷰 후 플레이 중앙값 9.7h vs 라이트 28.9h
어디서	한국어 리뷰어는 세 유형 모두 한국어 외 리뷰어보다 추천확률 중앙값이 낮다 (−15 ~ −39%p)

결론과 한계 - 2. 가설 판정과 시사점

가설	판정	근거
H1. 게임 경험이 많은 유형일수록 비판적일 것이다	조건부 지지	플레이시간이 비슷한 하드(55h)와 라이트(54h)를 비교하면 경험 많은 하드 쪽이 더 비판적(긍정률 57% vs 65%). 단, 가장 비판적인 집단은 경험이 아니라 리뷰 시점이 이른 초기 리뷰어
H2. 플레이시간이 짧은 시점에 쓴 리뷰일수록 부정적일 것이다	지지	초기 리뷰어 긍정률 48%로 최저. 하드·초기 리뷰어에서는 1단계 리뷰의 추천확률이 가장 낮음(라이트 리뷰어는 예외)

시사점 — 무엇을 먼저 고쳐야 하나

· 가장 부정적인 집단(초기 리뷰어)은 8시간·1스테이지에서 리뷰를 쓰고, 그중 절반은 곧 그만둔다. 초반 경험이 평가와 잔존을 함께 결정

· 불일치 비추천(텍스트 긍정·실제 비추천)은 초기 리뷰어에 가장 많다(3.5%). 그리고 전체적으로 일반 비추천자보다 리뷰 후 플레이가 길어 플레이 욕구가 남아 있는 집단 → 초반 불만을 고치면 되돌릴 여지가 가장 큰 1차 대상

· 불일치 추천(텍스트 부정·실제 추천)의 리뷰는 개선 요구 사항의 1차 자료. 더 많이 플레이한 뒤 추천을 유지한 채 불만을 쓰고, 리뷰 후에는 일반 추천자보다 빨리 떠난다 → 개선 시 플레이시간 증가를 기대

· 7스테이지의 공통적인 추천확률 하락은 그룹유형과 무관한 콘텐츠 문제일 가능성이 있음. 원인 확인은 후속 과제

· 한국어권은 별도 과제. 유형을 통제해도 낮으므로 유저 구성 차이로 설명되지 않음 → 현지화·가격·커뮤니티 요인 검토

결론과 한계 - 3. 한계와 후속 과제

한계

· 모집단: 업적이 공개된 리뷰어 72,271명(전체 리뷰 175,300건의 41%). 비공개 유저와 리뷰를 쓰지 않은 유저는 보지 못함. 제외한 업적 0개 999명 중 458명은 5시간 미만에 그만둔 조기 이탈자로 추정(긍정률 24%) — 포함했다면 초기 리뷰어의 부정 성향은 더 강하게 나왔을 것

· 언어별 성능 격차(AUC 한국어 0.89 ~ 독일어 0.98). 길이를 통제해도 남는 모델 자체의 격차라 한국어 결과는 이 오차를 감안. language는 클라이언트 설정값이라 실제 글의 언어와 다를 수 있음

· "무엇에" 실망했는지는 분석 범위 밖. 추천확률은 정도를 재지만 이유를 말하지 않음

· 관찰 데이터의 상관이지 인과가 아님. 리뷰 시점 값과 수집 시점(2026-09) 값이 섞여 있어 리뷰 후 플레이시간에는 최대 3년의 관측 창 차이가 포함됨

후속 과제

· 부정 리뷰 토픽 모델링으로 "무엇에" 답하기 (임베딩 군집 + c-TF-IDF)

· 7단계 하락 원인 확인 (해당 구간 리뷰 정독)

· 한국어권 낮은 평가의 원인 (현지화 관련 언급 비율)

· 출시 후 경과 시점(2023-09 → 2026-09)별 추세, 패치·DLC 전후 비교

· 제외한 조기 이탈 458명을 포함한 민감도 분석

참고문헌

[1] Enhancing churn forecasting with sentiment analysis of Steam reviews. Social Network Analysis and Mining (2024). https://link.springer.com/article/10.1007/s13278-024-01337-3

[2] Length and sentiment analysis of reviews about top-level video game genres on the Steam platform. Computers in Human Behavior (2023). https://doi.org/10.1016/j.chb.2023.107955

[3] Unravelling Player's Insights: A Comparative Analysis of Topic Modelling Techniques on Game Reviews. IEEE Transactions on Games (2024).

[4] Muennighoff, N. et al. (2023). MTEB: Massive Text Embedding Benchmark. EACL. https://aclanthology.org/2023.eacl-main.148/

[5] Xiao, C. et al. (2023). Length is a Curse and a Blessing for Document-level Semantics. EMNLP. https://aclanthology.org/2023.emnlp-main.86/

데이터·모델

· Steam Store appreviews API (https://store.steampowered.com/appreviews/1716740?json=1), Steam Web API GetPlayerAchievements — 수집 2026-09-08

· intfloat/multilingual-e5-large (Wang et al., 2024, arXiv:2402.05672) · Qwen/Qwen3-Embedding-0.6B (비교용)